

Lageparameter: x_D (Modus, Modalwert), x_Z (Median, Zentralwert, \bar{x} (Mittelwert), Quantil
 "Lage" der Elemente der GGH / Stichproben bezgl. Messskala, keine Aussage über Daten-Streuung,
Streuungsparameter: w (Spannweite), IQR, s^2 (Varianz), s (Standardabweichung), v (Varianzkoeffizient)
linksschief (rechtssteil): $x_D > x_Z > \bar{x}$, **rechtsschief (linkssteil):** $x_D < x_Z < \bar{x}$, metrische Verteilung $x_Z = \bar{x} = x_D$

2-dimensionale Häufigkeitsverteilung → Kreuztabelle
 M = Merkmal (A oder B), G = Geschlecht

M/G	m	w	Σ (Randverteilung)
A	400 40% 33,33%	800 80% 66,66%	1200 60% v 2000
B	600 60% 75%	200 20% 25%	800 40% v 2000
Σ	1000 50% v. 2000	1000 50% v. 2000	2000 100%

Randverteilung für eindim.. Häufigkeitsverteilung von G
 absolute Häufigkeit
 folgende Werte sind in d. Tabelle einzutragen
 relat. Spaltenhäufigkeit (z. B. 400 von 1000)
 relat. Zeilenhäufigkeit (z. B. 400 von 1200)
 % unter den Summen sind relative Werte der Zeilen- / Spaltensumme zu den Randverteilungen (Gesamtsumme)

Merkmals- ausprägung Anzahl der Handys	absolute Häufigk. Anz. Handy- Nutzer		relative Häufigk. h_i / n	abs. Summen- häufigk. $h_i + h_{i+1}$	rel. Summen- häufigk. $f_i + f_{i+1}$	arithm. Mittel $\Sigma(x_i * h_i) / n$ 25 / 20	Zwischen- rechnung für Varianz $(x_i - \bar{x})^2 * h_i$
x_i	h_i	$x_i * h_i$	f_i	H_i	F_i	\bar{x}	
1	16	16	0,80	16	0,8	1,25	1
2	3	6	0,15	19	0,95	1,25	1,687
3	1	3	0,05	20	1,00	1,25	3,063
Σ	$n = 20$	25	1,00	-	-	-	5,75

für klassierte Daten

$$r_i = \frac{h_i}{b_i}$$

$$h_i = r_i * b_i$$

$$n = \Sigma h_i = h_1 + h_2 + h_3$$

$$20 = 16 + h_2 + h_3 \quad | -16$$

$$4 = h_2 + h_3 \quad | -h_3$$

$$h_2 = 4 - h_3$$

$$\bar{x} = \frac{1}{n} \Sigma(x_i * h_i)$$

$$1,25 = \frac{1}{20} * 16 + 2h_2 + 3h_3 \quad | \cdot \frac{1}{20}$$

$$25 = 16 + 2 * (4 - h_3) + h_3 \quad | -16$$

$$9 = 8 - 2h_3 + h_3 \quad | -8$$

$$1 = -2h_3 + h_3 \Rightarrow h_3 = 1$$

$$h_2 = 4 - h_3 = 4 - 1 = 3$$

Mittelwert \bar{x} $\bar{x} = \frac{1}{n} \Sigma x_i * h_i$

Mittelwert \bar{x} bei klassierten Daten wie bei unklassierten Daten nur mit Klassenmitte m_i

$$\bar{x} = \frac{1}{n} \Sigma m_i * h_i \quad m_i \text{ (Klassenmitte: } = \frac{1}{2} * (x_{k-1} + x_k) * h_i$$

Klassenbreite $b_i = x_k - x_{k-1}$ Bsp. Klasse „20 b. u. 35“: Klassenbreite $b_i = 35 - 20 = 15$

Varianz s^2 auf Grund der Quadrierung immer ≥ 0

arithmetische Mittel der Abweichungsquadrate

wichtiger Streuungsparameter, f metrische Merkmale, Ausgangswert f. Standardabweichung & Variationskoeffizient

$$s^2 = \frac{1}{n} \Sigma (x_i - \bar{x})^2 * h_i$$

$$s^2 = 1/n * ((x_1 - \bar{x})^2 * h_1 + (x_2 - \bar{x})^2 * h_2 + (x_3 - \bar{x})^2 * h_3)$$

$$s^2 = 1/20 * ((1 - 1,25)^2 * 16 + (2 - 1,25)^2 * 3 + (3 - 1,25)^2 * 1)$$

Varianz s^2 bei klassierten Daten

$$s^2 = \frac{1}{n} \Sigma_{i=1}^n (m_i - \bar{x})^2 * h_i \quad \text{wie bei unklassierten Daten nur mit Klassenmitte } m_i \text{ statt mit } x_i$$

Standardabweichung (durchschn. Abweichung, Standardfehler) $s \Rightarrow$ **Streuung in einer Stichprobe**

$$s = \sqrt{s^2} = \sqrt{0,2875} = 0,536$$

Varianzkoeffizient v

$$v = s / \bar{x} \quad \text{Standardabweichung } s / \text{Mittelwert } \bar{x}$$

Relatives Streuungsmaß (Streuungsparameter), dimensionslose Größe, **prozentuales Verhältnis der Standardabweichung zum arithmetischen Mittel, zum Vergleich der Streuung zwischen verschiedenen Erhebungen**

Modus x_D → Beobachtungswert mit der größten Häufigkeit → mehrere Merkmalsausprägungen mit der gleichen maximalen Häufigkeit = mehrere Modalwerte; Beobachtungsw. mit Häufigkeit == 1 → kein Modus! → Modus x_D aus o. g. Tabelle ist 1
bei klassierten Daten ist Modalwert die Mitte der Klasse mit den größten Häufigkeiten (Modalklasse), Modalwert = m_i

Spannweite w

$$W = x_{\max} - x_{\min}$$

auch bei klassierten Daten!

Quartile → $Q_1, Q_2, Q_3 \Rightarrow Q_2$ -Quartil = Median / Zentralwert \bar{x}_Z

Beobachtungs-Werte müssen geordnet sein!

Median x_Z : mind. 50% der Beobachtungswerte (n) liegen links und rechts des Medians $x_Z = x_{n+1} * 1/2$

wenn n ungerade, z. B. $n = 21 \Rightarrow x_{21+1} * 1/2 = x_{11}$ wenn n gerade, z. B. $n = 20 \Rightarrow (x_{20} * 1/2 + x_{20} * 1/2 + 1) = (x_{10} + x_{11}) * 1/2$

Interquartilsabstand IQR = $Q_3 - Q_1$

Streuungsmaß, Differenz zwischen oberem und unterem Quartil enthält 50% der Verteilung.


Boxplot: enthält $x_{\min}, Q_1, \text{Median}, Q_3, x_{\max}$

informiert über Streuungsmaße Spannweite ($x_{\max} - x_{\min}$), IQR
 Schiefe und Ausreißer

x_{\min} und x_{\max} , auch bei klassierten Daten

Achsenbeschriftung und Legende („mit Migrationshintergr.“)
 nicht vergessen, beides unterhalb des Boxplots
 Achse enthält die Skala zu den x-Werten.

bei klassierten
 Daten werden
 \bar{x} , s^2 , s , v wie
 bei
 unklassierten
 Daten im Casio
 berechnet.
 Statt x_i wird m_i
 (Klassenmitte)
 in Tabelle
 eingetragen



Median bei klassierten Daten

$$\bar{x}_Z = x_{k-1} + (x_k - x_{k-1}) \cdot \frac{(0,5 - F_{k-1})}{f_k}$$

x_{k-1} = K-Untergrenze, x_k = K-Obergrenze

bei Q1, Q3 wird genauso verfahren.

Die Einfallsklasse muss rel. Summenhäufigkeit $F_i \geq 25\%$ (bei Q1) bzw. $F_i \geq 75\%$ (bei Q3) haben.

Für den %-Wert im Zähler des Bruchs wird statt 0,5 \Rightarrow 0,25 (für Q1) bzw. 0,75 (für Q3) genommen

k = Einfallsklasse \Rightarrow Klasse mit rel. Summenhäufigkeit $F_i \geq 50\%$,

x_{k-1} = Untergrenze d. Einfallsklasse, x_k = Obergrenze d. Einfallsklasse,

F_{k-1} = relative Summenhäufigkeit der Klasse unterhalb (vor) der Einfallsklasse

f_k = relative Häufigkeit der Einfallsklasse

x_i	h_i	f_i	H_i	F_i
10 b. u. 30	60	30	60	30
30 b. u. 40	80	40	140	70
40 b. u. 70	60	30	200	100
Σ	200	100	-	-

Einfallsklasse ist k_2 „30 b. u. 40“, da $F_i \geq 50$ (in Klasse „10 b. u. 30“ ist $F_i < 50$)

Hinweis. %-Werte immer als Dezimalwerte schreiben

$$\bar{x}_Z = 30 + (40 - 30) \cdot \frac{(0,5 - 0,3)}{0,4} = 30 + 10 \cdot \frac{(0,5 - 0,3)}{0,4}$$

Korrelationsanalyse \Rightarrow Zusammenhangsanalyse (Interdependenzanalyse) zwischen 2 metrischen Merkmalen X, Y

K-Analyse prüft, ob zwei Variablen X und Y linear zusammenhängen und prüft die Stärke des Zusammenhangs analysiert Wechselwirkung der Variablen X, Y untereinander (wie beeinflussen sich die Variablen gegenseitig?)

Korrelationskoeffizient r_{xy} : Zusammenhangsmaß (Assoziationsmaß) für Quantifizierung der Korrelation $-1 \leq r_{xy} \leq +1$

Korrelation \Rightarrow zahlenmäßiger statistischer Zusammenhang zwischen 2 Merkmalen X und Y

positive K. ($r > 0$): gleichförmige Entwicklung von X und Y (hoher Wert von X \Rightarrow auch hoher Wert von Y)

negative K. ($r < 0$): gegenläufige Entwicklung von X und Y (hoher Wert von X \Rightarrow jedoch niedriger Wert von Y)

$r = -1$: extrem starker negativer linearer Zusammenhang \Rightarrow Punktwolke mit negativer Steigung (l. o. nach r. u.)

Korr. trifft aber KEINE Aussage zum kausalen Zusammenhang und zur Kausalitätsrichtung, jedoch Voraussetzung für Erklärung eines kausalen Zusammenhangs (kausaler Zusammenhang \Rightarrow ist Ursache-Wirkungs-Beziehung zwischen X und Y \Rightarrow Veränderung des abhängigen Merkmals Y basiert auf Veränderung von X)

Korrelationskoeffizient r_{xy} : Wertebereich: $-1 \leq r_{xy} \leq +1$

- dimensionsloses Maß für den Grad des linearen Zusammenhangs (Stärke und Richtung des lin. Zusammenhangs)

K-Koeffizient r für 2 mind. intervallskalierte Merkmale X und Y, m. positiver Kovarianz $\text{cov}(x,y)$ & Standardabweichung s

K-Koeffizient r berechnet sich aus dem Quotienten aus Kovarianz $\text{cov}(x,y)$: und Standardabweichung s

$$r_{xy} = \frac{(\frac{1}{n} \sum x_i \cdot y_i) - \bar{x} \cdot \bar{y}}{\sqrt{(\frac{1}{n} \sum x_i^2) - \bar{x}^2} \cdot \sqrt{(\frac{1}{n} \sum y_i^2) - \bar{y}^2}}$$

$$r_{xy} = \frac{(\frac{1}{4} \cdot 450) - 4 \cdot 25}{\sqrt{(\frac{1}{4} \cdot 74) - 16} \cdot \sqrt{(\frac{1}{4} \cdot 3000) - 625}}$$

für Kovarianz $\text{cov}(x,y)$ $(\frac{1}{n} \cdot \sum x \cdot y) - (\bar{x} \cdot \bar{y})$ im Zähler

$(\frac{1}{n} \sum x_i \cdot y_i)$ bezieht sich auf die Summe des zuvor zu $(x_i \cdot y_i)$

berechneten Produkts (nicht die Summen von x und y multiplizieren, sondern das in jeder Tabellen-Zeile berechnete Produkt aus $(x_i \cdot y_i)$ addieren (hier 450) !

für Standardabweichung s im Nenner

gilt dasselbe. Quadrate für x_i, y_i summieren (= 74 und 3000) und \bar{x}^2 bzw. \bar{y}^2 subtrahieren.

Bsp:

Werte in Tabelle erfassen:

Werte in Tab. 1						Summen zu allen Werten		Mittelwert zu x _i und y _i		Quadrate zu Mittelwerten	
x _i , y _i	&	x _i · y _i	&	x _i ² , y _i ²	&						
Filial-Nr i		x _i VK- Fläche Tsd. m ²		y _i Umsatz (Mio €)		x _i ²	y _i ²	x _i · y _i			
1		3		30		9	900	90			
2		2		10		4	100	20			
3		6		40		36	1600	240			
4		5		20		25	400	100			
n = 4		Σ		16		100	74	3000	450		
$\bar{x} = 4$		(16 : 4)		$\bar{y} = 25$		(100 : 4)					
$\bar{x}^2 = 16$				$\bar{y}^2 = 625$							

$$r_{x,y} = \frac{(\frac{1}{n} \sum x_i \cdot y_i) - \bar{x} \cdot \bar{y}}{\sqrt{(\frac{1}{n} \sum x_i^2) - \bar{x}^2} \cdot \sqrt{(\frac{1}{n} \sum y_i^2) - \bar{y}^2}}$$
$$r_{xy} = \frac{(\frac{1}{4} \cdot 450) - 4 \cdot 25}{\sqrt{(\frac{1}{4} \cdot 74) - 16} \cdot \sqrt{(\frac{1}{4} \cdot 3000) - 625}} = \frac{112,5 - 100}{\sqrt{18,5 - 16} \cdot \sqrt{750 - 625}}$$
$$\frac{12,5}{\sqrt{2,5} \cdot \sqrt{125}} = \frac{12,5}{\sqrt{1581} \cdot \sqrt{11,180}} = \frac{12,5}{17,676} = 0,707$$

$$r_{xy} = \frac{(\frac{1}{n} \sum x_i \cdot y_i) - \bar{x} \cdot \bar{y}}{\sqrt{(\frac{1}{n} \sum x_i^2) - \bar{x}^2} \cdot \sqrt{(\frac{1}{n} \sum y_i^2) - \bar{y}^2}}$$

$$r_{xy} = \frac{(\frac{1}{4} \cdot 450) - 4 \cdot 25}{\sqrt{(\frac{1}{4} \cdot 74) - 16} \cdot \sqrt{(\frac{1}{4} \cdot 3000) - 625}} = \frac{112,5 - 100}{\sqrt{18,5 - 16} \cdot \sqrt{750 - 625}}$$

$$= \frac{12,5}{\sqrt{2,5} \cdot \sqrt{125}} = \frac{12,5}{\sqrt{1,581} \cdot \sqrt{11,180}} = \frac{12,5}{17,676} = 0,707$$

Interpretation d. Korrelationskoeffizienten r_{xy} : nur Orientierungswerte \rightarrow Entscheidung immer problembezogen

-1 bis -0,8 „starke“ negative Korrelation, -0,8 bis -0,5 „mittlere“ neg. K., -0,5 bis 0 „schwache“ K., 0 keine Korrelation

Regressionsanalyse \Rightarrow Abhängigkeitsanalyse (Dependenzanalyse) für gerichteten Zusammenhang

ist Abhängigkeitsanalyse zwischen 2 Merkmalen X, Y; Unterscheidung zwischen unabhängigen und abhängigen Merkmalen R-Analyse basiert auf Regressionsfunktion $\hat{y} = a + b \cdot x \Rightarrow$ R-Funktion ermittelt Abhängigkeitsmaß

einfache Regressionsanalyse mit 2 metrischen Größen: Zielgröße Y ist Regressand (abhängiges Merkmal), Einflussgröße X ist Regressor (unabh. Merkmal); Zweck: Erstellen v. Vorhersagemodelle, Quantifizierung d. Stärke d. Zusammenhangs

Bestimmtheitsmaß $R^2 = (r_{xy})^2 \Rightarrow$ immer in % angeben! (Quadrat der Korrelationskoeffizienten r in %) immer ≥ 0

0% $\leq R^2 \leq 100\%$ (bzw. $0 \leq R^2 \leq 1$) aus o. g. Bsp: $r_{xy} = 0,707 \Rightarrow R^2 = (r_{xy})^2 = 0,707^2 = 0,50 = 50\%$

Gütemaß der lin. Regression (Erklärungskraft d. Modells: wie gut entspricht das Modell der Realität $R^2 = 100\% =$ perfektes Modell); wie gut erklärt die unabhängige Variable (Regressor) X, die Varianz der abhängigen Variable Y (Regressand) = der durch Varianz des unabhängigen Merkmals X erklärbare Anteil der Varianz d. abhängigen Merkmals Y (Residualvarianz) \Rightarrow Varianz d. abhängigen Merkmals ist in erklärbare und nicht erklärbare Varianz zerlegbar

Antwort um Bsp. 50% der Varianz zu den Umsätzen lassen sich durch Varianz der Verkaufsflächen erklären. Die übrigen 50% der Varianz in den Umsätzen sind durch andere Einflussgrößen erklärbar.

R^2 im Diagramm: je mehr Datenpunkte auf einer Linie, umso höher R^2 . Streuen Datenpunkte o. Zusammenhang, dann R^2 nahe 0

Regressionsfunktion (Dependenzanalyse)

Voraussetzungen: X, Y sind quantitative (metrische) Merkmale, linearer Zusammenhang zwischen X → Y

Regressionsfunktion $\hat{y} = a + b \cdot x$ (nach Methode der kleinsten Quadrate) $\Rightarrow x = (\hat{y} - a) / b$

Regressionskoeffizienten a, b \Rightarrow linearer Zusammenhang durch Gerade in Punktwolke

Summe der quadratischen Abweichungen von a und b (Kurvenparameter) soll zu beobachteten Punkten minimal sein

Berechnung des Regressionskoeffizienten a

Berechnung des Regressionskoeffizienten b

$$a = \frac{\sum x_i^2 \cdot \sum y_i - \sum x_i \cdot \sum (x_i \cdot y_i)}{n \cdot \sum x_i^2 - (\sum x_i)^2}$$

$$b = \frac{n \cdot \sum (x_i \cdot y_i) - \sum x_i \cdot \sum y_i}{n \cdot \sum x_i^2 - (\sum x_i)^2}$$

Formel im Nenner ist in beiden Gleichungen identisch

Bsp. zum Zusammenhang von VK-Fläche und Umsatz \Rightarrow Tabelle mit Hilfsgrößen

Filialen-Nr. i	x_i VK-fläche (1000 qm)	y_i Umsatz (Mio €)	x_i^2	y_i^2	$x_i \cdot y_i$	\hat{y} $= a + b \cdot x$ $= 5 + 5 \cdot x$
1	3	30	9	900	90	20
2	2	10	4	100	20	15
3	6	40	36	1600	240	35
4	5	20	25	400	100	30
n = 4	Σ	100	74	3.000	450	100

Interpretation der R-Koeffizienten a und b:

a ist konstante Größe und ist unabhängig von Einflussgröße,

b ist variabler Faktor im veränderl. Term der R-Rechnung, b ist abhängig von Einflussgröße (unabhängiger Variable) x

\hat{y} erhöht/vermindert sich um (Wert d. R-Koeffiz. a) $\hat{y} = a + b \cdot x$ $\hat{y} = 5 + 5 \cdot x$

$$a = \frac{74 \cdot 100 - 16 \cdot 450}{4 \cdot 74 - 16^2} = \frac{7400 - 7200}{296 - 256} = \frac{200}{40} = 5$$

$$b = \frac{4 \cdot 450 - 16 \cdot 100}{4 \cdot 74 - 16^2} = \frac{1800 - 1600}{296 - 256} = \frac{200}{40} = 5$$

Varianz d. Residuen: $s_y^2 = (\frac{1}{n} \cdot \sum \hat{y}_i^2) - \bar{y}^2$ in Hilfstabelle 1 Spalte mit werten aus $\hat{y} = a + b \cdot x \Rightarrow$ Quadrate jedes \hat{y}

addieren und durch n dividieren; davon Quadrat zum Mittelwert von \bar{y}^2 subtrahieren $\Rightarrow \frac{1}{4} \cdot (20^2 + 15^2 + 35^2 + 30^2) - 25^2$

Varianz der Regressionswerte wird durch die Varianz d. unabhängigen Merkmals bestimmt

Lineare Korrelation und Regression erfassen nur lineare Zusammenhänge und sind anfällig für Ausreißer

Im Streudiagramm: Punkte (kleine Vierecke) anhand der Koordinaten x, y aus d. Tabelle zeichnen (Achsbeschriftung!)

Für Regressionsgerade 1 Punkt zur Y-Achse anhand der Regressionsfunktion berechnen. Dabei einen Wert für X aus Tabelle einsetzen. Für den 1. Punkt der Gerade wird x = 0 eingesetzt $\Rightarrow \hat{y}$ dann = R-Koeffizient a, x = 0. Für 2. Punkt: y = zuvor

berechneter Punkt ($\hat{y} = a + b \cdot x$). Beide Punkte zu Y und X im Diagramm zeichnen und verbinden \Rightarrow R-Gerade muss über das gesamte Diagramm gehen

Wahrscheinlichkeitsrechnung

$$(A \cup B) \cup C = A \cup (B \cup C) \Leftrightarrow (A \cap B) \cap C = A \cap (B \cap C)$$

$$A \cup (B \cap C) = (A \cup B) \cap (A \cup C) \Leftrightarrow A \cap (B \cup C) = (A \cap B) \cup (A \cap C)$$

$$A \cup B = B \cup A \Leftrightarrow A \cap B = B \cap A$$

$$A \setminus B = A \cap B^c$$

Mengenoperationen

$A \cup B$ = Vereinigungsmenge \Rightarrow Objekte in A ODER B $\Rightarrow (x \in A) \vee (x \in B) \Rightarrow$ Addition

$A \cap B$ = Schnittmenge \Rightarrow Objekte in A UND B $\Rightarrow (x \in A) \wedge (x \in B) \Rightarrow$ Multiplikation

$A \setminus B$ = Differenzmenge \Rightarrow Objekte, in A aber NICHT in B $\Rightarrow (x \in A) \wedge (x \notin B) \Rightarrow$ Subtraktion A - B

B^c oder \bar{B} Komplement v. B in Bezug auf A \Rightarrow A OHNE B $\Rightarrow \{x \mid x \notin B\} \Rightarrow$ Gesamtmenge ohne Elemente (Objekte) aus B

\Rightarrow Subtraktion: $\Omega = 1 - |B|$ (= Komplementärmenge \Rightarrow Gegenwahrscheinlichkeit)

Multiplikationsregel der Kombinatorik: mehrfache Auswahl \Rightarrow mögliche Fälle $m_1 \cdot m_2 \cdot m_3$

z. B. 100 Tonfiguren, 20% fehlerhaft, P für 4 fehlerfreie Figuren

$$m_1 = \frac{80}{100} \text{ (80\% fehlerfrei, 20\% fehlerhaft, 100 gesamt)}, m_2 = \frac{79}{99} \text{ usw. } \frac{80}{100} \cdot \frac{79}{99} \cdot \frac{78}{98} \cdot \frac{77}{97} = 0,40$$

$$P. \text{ zur Los-Auswahl v. 5 Angriffsspielern bei 10 Spielern: } P(A_i) = \frac{k_i}{n_i} \quad k_i \text{ ist } E, n_i \text{ ist } \Omega \quad P = \left(\frac{5}{10} \cdot \frac{4}{9} \cdot \frac{3}{8} \cdot \frac{2}{7} \cdot \frac{1}{6} \right)$$

Permutat. m Wiederholung; Anordnung der k-Elemente \Rightarrow Schlüsselwörter „Anzahl“, „Wie viele“

Anzahl d. Möglichkeiten zur Anordnung von Buchstaben oder Anzahl der Kombis f. Perlen auf Kette

$$\frac{n!}{n_1! \cdot n_2! \cdot \dots \cdot n_k!} \quad \text{ODER im Casio } 6 + \text{SHIFT} + \text{Taste "X"} + 3 ==> 6 P3$$

$$\text{ELEVEN} = 6 \text{ Buchstaben, 4 B-Typen} \Rightarrow 3 \text{ x „E“, 1 x „L“, 1 x „V“, 1 x „N“} = \binom{6}{3} \text{ ODER } \frac{6!}{3!} \quad (\text{Fakultät 1 fällt raus})$$

Wie viele dieser „Worte“ enthalten die drei E's direkt hintereinander?

Sonderfall: „E“ soll hintereinander folgen $\Rightarrow 3 \text{ E's} = 1 \text{ Zeichen} \Rightarrow \text{„ELVN“}, \Rightarrow$ daher keine Fakultät im Nenner $\Rightarrow 4! = 24$

Wie viele dieser „Worte“ beginnen mit E und enden mit N?

$$\text{„E“ und „N“ am Beginn/Ende v. (E)LEVE(N) nicht berücksichtigen} \Rightarrow \text{„LEVE“} \Rightarrow n = 4 \text{ und } k = 2 \quad (2 \text{ x „E“}) = \binom{4}{2} \text{ ODER } \frac{4!}{2!};$$

bedingte Wahrscheinlichk. $P(A|B)$ \Rightarrow Wahrscheinlich für Ereignis A nach Ereignis B (B ist d. 1. Bedingung im Graph)

„Satz der totalen Wahrscheinlichkeit“: Ermittlung P(A) unter EINER Voraussetzung P(B)

$$P(A) = \sum P(A|B) \cdot P(B) = P(A|B) \cdot P(B) + P(A|\bar{B}) \cdot P(\bar{B}) \Rightarrow P(p) = P(p|M) \cdot P(M) + P(p|F) \cdot P(F) \quad (\text{im Pfad multiplizieren})$$

Satz von Bayes: Ermittlung P(A) unter ZWEI Voraussetzungen: P(A|B) und P(B)

$$P(B_i|A) = \frac{P(A|B_i) \cdot P(B_i)}{\sum_{i=1}^n P(A|B_i) \cdot P(B_i)} \quad P(F|s) = \frac{P(s|F) \cdot P(F)}{P(s|F) \cdot P(F) + P(s|M) \cdot P(M)}$$

bedingte W.: 4 rote, 6 blaue, zweimal Ziehen \Rightarrow ist 1. Ball blau wird zurückgelegt, ist 2 Ball rot, wird nicht zurückgelegt

1. Kugel blau? $\Rightarrow P(\text{blaue im 1. Zug}) = 6/10; P(\text{rote im 1. Zug}) = 4/10; P(\text{blaue im 2. Zug}) = 6/10; P(\text{rote im 2. Zug}) = 4/10$

1. Kugel rot? $\Rightarrow P(\text{blaue im 1. Zug}) = 6/10; P(\text{rote im 1. Zug}) = 4/10; P(\text{blaue im 2. Zug}) = 6/9; P(\text{rote im 2. Zug}) = 3/9$

> blaue im 1. Zug und rote Kugel im 2. Zug: $P(A) = 6/10 \cdot 4/10 = 0,24$

> 2 blaue: $6/10 \cdot 6/10 + 6/10 \cdot 6/9 = 0,76$ > 2 rote: $4/10 \cdot 4/10 + 4/10 \cdot 3/9 = 0,29$

mit Reihenfolge, mit Zurücklegen $\Rightarrow V_{mw} \Rightarrow |\Omega| = n^k$

4 x würfeln, P für verschiedene Zahlen? $\Rightarrow n = 6, k = 4 \quad |\Omega| = 6^4 = 1296 \quad |E| = \text{Vow} = \frac{6!}{(6-4)!} = 360$

Wörter der Länge 3 aus 5 Buchstaben. P für Wörter mit 2 verschied. B? $|\Omega| = 3^5 = 125 \quad |E| = \frac{5!}{(5-3)!} = 60$

3 rote, 4 bl., 5 grü. Bälle $\Rightarrow 3 \times$ Ziehen mit Zurückkl, gefragt: n f. **verschieden. Farben** $n=12, k=3 \quad \Omega=12^3 \quad E=3 \cdot 4 \cdot 5 = 60$
3 rote, 4 bl., 5 gr Bälle $\Rightarrow 3 \times$ Ziehen mit Zurückkl, gefragt: n für **gleiche Farben** $\Omega=12^3 \quad E=3^3 + 4^3 + 5^3 = 216$

bei verschiedenen Farben (= beliebige Kombi d. Möglichkeiten) \Rightarrow **Multiplikation**,
bei gleichen Farben (keine Kombi, da sortiert (gefiltert) nach Farben) \Rightarrow **Addition**

mit Reihenfolge, ohne Zurücklegen $\Rightarrow V_{ow} \Rightarrow |\Omega| = \binom{n}{k} \cdot k! \quad \text{oder} \quad \frac{n!}{(n-k)!}$ Bruch kürzen, falls n sehr groß

Sonderfall wenn $n = k$, dann $|\Omega| = n!$ Anzahl Mögl. 5 Leute auf 5 freie (unterscheidbare) Plätze zu verteilen? \Rightarrow **Fakultät 5!**

4 x würfeln, W für verschiedene Zahlen? $\Rightarrow n = 6, k = 4 \quad |\Omega| = V_{mw} 6^4 = 1296 \quad |E| = \text{Vow} = \frac{6!}{(6-4)!} = 360$

100 Sportler, **1 Wettbewerb**, Anzahl d. Ausgänge f. 1. Platz, 2. Platz ... $\Omega = \text{Vow} = \frac{100!}{(100-3)!}$

mit Reihenfolge da Reihenf. d. Plätze gefragt. **ohne Wiederholung** da nur 1 Wettbewerb

ohne Reihenfolge, mit Zurücklegen $\Rightarrow K_{mw} \Rightarrow |\Omega| = \binom{n+k-1}{k} \quad \text{oder} \quad \frac{(n+k-1)!}{k! \cdot (n-1)!}$

10 Sportler in **3 Wettbewerben**, jeder Wettbewerb genau eine Sieger. Wie viele Arten für Verteilung d. Preise?

$n = 10$ (Sportler), $k = 3 \quad |\Omega| = \text{Vow} = \binom{10+3-1}{3} = \binom{12}{3} = 220$ ohne Reihenf., weil Rangfolge d. Plätze nicht gefragt

ohne Reihenfolge, ohne Zurücklegen $\Rightarrow K_{ow} \Rightarrow \Omega = \binom{n}{k} \quad \text{oder} \quad \frac{n!}{k! \cdot (n-k)!}$ (**Binomialkoeffizient**); k Elemente aus Menge n

gleichz. Ziehen v. **3 Pack aus 20 Pack; 5 Pack sind 2. Wahl** \Rightarrow **ohne Reihenfolge, ohne Zurücklegen** $\Rightarrow \binom{n}{k}$

genau 1 beschäd. Pack, $n=20, k=3 \Rightarrow \Omega = \binom{20}{3} = 1140 \Rightarrow$ für |E|: $n_2 = 5$ (2. Wahl), $k = 1$ (besch. Pack);

$E = \binom{5}{1} \cdot \binom{15}{2} = 525 \Rightarrow P(A) = \frac{525}{1140} = 0,46$

höchstens 1 Pack: $E = \binom{5}{1} \cdot \binom{15}{2} + \binom{5}{0} \cdot \binom{15}{3} = 980 \Rightarrow P(B) = \frac{980}{1140} = 0,86$

mind. 1 Pack: $E = \binom{5}{0} \cdot \binom{15}{3} = 455 \Rightarrow$ Gegenw.: $1 - \text{keine} \Rightarrow P(C) = 1 - \frac{455}{1140} = 0,60$

nacheinander Ziehen mit Zurücklegen v. 3 Pack aus 20 Pack; 5 Pack sind 2. Wahl \Rightarrow **mit Reihenfolge, mit Zurücklegen selbiger Algo, wie oben, jedoch mit n^k UND zusätzlich $k = 3$ (Anzahl gezogener Pack) als Faktor**

$\Omega = 20^3 = 8000$ **genau 1 Packung**: $E = 3 \cdot 5^1 \cdot 15^2 = 3375 \quad P(A) = \frac{3375}{8000} = 0,42$

höchstens 1 Packung $\Rightarrow E = 3 \cdot 5^1 \cdot 15^2 + 5^0 \cdot 15^3 = 3375 + 3375 = 6750 \quad P(B) = \frac{6750}{8000} = 0,84$

mind. 1 Packung \Rightarrow Gegenwahrscheinlich: $1 - \text{keine} \Rightarrow E = 5^0 \cdot 15^3 = 3375 \Rightarrow P(C) = 1 - \frac{3375}{8000} = 0,58$

3 Parteien A, B, C mit jeweils 7 Mitglied. soll ein **6-köpfiger Ausschuss** gebildet werden. Wie viele Zusammensetz., gesamt?

3 Parteien haben gesamt $7 \cdot 3 = 21$ Mitglieder \Rightarrow Varianten für 6 köpfigen Ausschuss $\Omega = \binom{21}{6} = 54264$

Wie viele Ausschusszusammensetzungen, wenn mindestens ein A-Mitglied dabei sein soll?

$\Omega = 21 - \text{„ohne A“} \Rightarrow$ Von Ω Anteil der |B| und |C|-Mitglieder ($2 \times 7 = 14$) subtrahieren $|\Omega| - |A| = \binom{21}{6} - \binom{14}{6} = 51.261$

6 rote, 4 grüne, 5 gleichzeitig Ziehen $\Rightarrow K_{ow}$, gefragt: 2 rote $\Rightarrow |\Omega| = \binom{10}{5} = 252 \quad |E| = \binom{6}{2} \cdot \binom{4}{3} = 160$

3 rote, 4 bl, 5 gr $\Rightarrow 3$ gleichz. Ziehen $\Rightarrow K_{ow}$, gefragt: alle unterschiedl. Farbe: $|\Omega| = \binom{12}{3} \quad |E| = \binom{3}{3} \cdot \binom{4}{3} \cdot \binom{5}{3}$

3 rote, 4 bl, 5 gr $\Rightarrow 3$ gleichz. Ziehen $\Rightarrow K_{ow}$, gefragt: alle gleiche Farbe: $|\Omega| = \binom{12}{3} \quad |E| = \binom{3}{3} + \binom{4}{3} + \binom{5}{3}$

100 Figuren, 20% fehlerh, 80% fehlerfrei., 4 werden entn., W. für 4 fehlerfreie $\frac{80}{100} \cdot \frac{79}{99} \cdot \frac{78}{98} \cdot \frac{77}{97}$ Multipl. da beliebige Kombi,

Wahrscheinlichk. für 3 fehlerfreie aus 4 entnommenen $\Rightarrow K_{ow} \quad |\Omega| = \binom{100}{4} \quad E = \binom{80}{3} \cdot \binom{20}{1}$

100 Sportler, **1 Wettbewerb**, Anzahl d. Ausgänge f. die ersten 3 Plätze $\Omega = K_{ow} = \binom{100}{3}$

ohne Reihenfolge da keine Reihenf. d. Plätze gefragt (nur die ersten 3 Plätze). **ohne Wiederholung** da nur 1 Wettbewerb

Siebformel (Schlüsselwörter: „Anzahl“, „Wie viele“)

2 Mengen: $A \cup B = A + B - A \cap B$

Wie viele Ausschusszusammensetzungen für EINEN 6-köpfigen Ausschuss mit mind. ein A-Mitglied und ein B-Mitglied?

$\Omega - A + B - A \cap B \Rightarrow \binom{21}{6} - \left(\binom{14}{6} + \binom{14}{6} - \binom{7}{6} \right) = \binom{21}{6} - 2 \cdot \binom{14}{6} + \binom{7}{6} = 48.265$

Wahrscheinlichkeit bei **2 (aufeinanderfolgenden) Würfeln mindestens eine 5** zu erzielen?

$(A + B) - (A \cap B) \quad P(\text{mind. eine 5 in 2 Würfeln}) = \frac{1}{6} + \frac{1}{6} - \left(\frac{1}{6} \cdot \frac{1}{6} \right) = \frac{11}{36}$ gefragte Zahl ist egal, selbes Ergebnis m. 4 oder 3

3 Mengen: $A \cup B \cup C = A + B + C - (A \cap B) - (A \cap C) - (B \cap C) + (A \cap B \cap C)$

Wie viele Ausschusszusammensetzungen, wenn aus jeder der drei Parteien mindestens ein Mitglied dabei sein soll

$\Omega - A + B + C - (A \cap B) - (A \cap C) - (B \cap C) + (A \cap B \cap C) \Rightarrow \binom{21}{6} - 3 \cdot \binom{14}{6} + 3 \cdot \binom{7}{6} - 0 = 45.276$

Studenten mit versch. Kursen

Gegenwahrscheinlichk. Wahrscheinlichkeit bei 5 (aufeinanderfolgenden) Würfeln wenigstens einmal eine 4 zu erzielen?

$P(A) = 1 - P(\bar{A}) \Rightarrow (\text{min. eine 4 in 5 Würfeln}) = 1 - \frac{5}{6} \cdot \frac{5}{6} \cdot \frac{5}{6} \cdot \frac{5}{6} \cdot \frac{5}{6} \Rightarrow \frac{5}{6} = \text{Wahrscheinlichk. von 5:6 keine 4 zu würfeln,}$

Wahrscheinlichkeit kein Pferd im Schachspiel: Figuren im Spiel $n = 32$, $n(\text{Pferde}) = 4 \Rightarrow P(\text{kein Pferd}) = 1 - 4:32$

2 x 1 Kugel m. Zurückkl. aus 1 Urne. W. für mind. eine blauen Kugel $\frac{95}{144}$. gefragt W. für rote Kugel $P = \sqrt{1 - \frac{95}{144}}$

Diagramme

WICHTIG: sprechende Achsenbeschriftungen, sinnvolle Skaleneinteilung, ggf. Legende

Säulendiagramm

- höhenproportionale Häufigkeitsverteilung (senkrechte nicht aneinandergrenzende Säulen); Säulen können beliebig breit sein; y-Achse zur abs. Häufigkeit h_i , x-Achse zu x-Werten, für wenige Ausprägungen

Stabdiagramm (Liniendiagramm) ➔ wie Säulendiagramm nur mit schmalen Säulen

Balkendiagramm ➔ am häufigsten verwendet, wie Säulendiagramm nur mit horizontalen Balken (y-Achse zu x-Werten; x-Achse zur abs. Häufigkeit h_i)

Kreisdiagramm ➔ nur für eine Datenreihe, keine negativen Werte, keine 0-Werte, Kategorien repräsentieren Teile des gesamten Kreisdiagramms, max. 7 Teilwerte

Histogramm

- **flächenproportionale Darstellung der absoluten oder relativen** (beide sind möglich) **Häufigkeiten** von ausschließlich klassierten Daten

- **x-Achse**: Werte müssen auf Skala geordnet sein und gleiche Abstände haben,

x-Achse enthält **aneinandergrenzende Rechtecke zur Klassenbreite, keine Abstände zwischen den Flächen**

- **y-Achse**: **Rechteckhöhe Höhe = Häufigkeitskoeffizient** berechnet aus ($r_i = h_i / b_i$ (Klassenbreite)) oder (f_i / b_i),

Skaleneinteilung entsprechend den berechneten Werten, **in den Rechtecken den Wert zur relativen Häufigkeit f_i eintragen**


empirische Verteilungsfunktion (Treppenfunktion) $F(x)$ ist (**relative**) **Summenhäufigkeitskurve**

- **x-Achse enthält x-Werte oder Klassengrenzen**,

- bei klassierten Daten werden die Punkte / Striche im Diagramm bei K-Obergrenze gezeichnet

- y-Achse enthält Skala zur relativen Summen-Häufigkeit F_i ;

- **Punkt oder Strich (oder Punkt mit Strich) wird zur Summenhäufigkeit auf y-Achse und zum x-Wert bzw. zur K-Obergrenze auf x-Achse gezeichnet**



Streudiagramm

graphische Darstellung zur Abhängigkeit (Regression) und zum Zusammenhang (Korrelation) von **beobachteten Wertepaaren zweier Merkmale X, Y**

Wertepaare werden in kartesisches Koordinatensystem eingetragen ➔ ergibt Punktwolke

Stärke und Richtung des Zusammenhangs anhand der Lage und Form der Punktwolke;

erste Hinweise über mögliche Abhängigkeit zwischen Merkmalen

Boxplot

W-Graph (Baumdiagramm)