

WIRTSCHAFTSSTATISTIK

MODUL 4: LAGEPARAMETER

WS 2020/21

DR. E. MERINS

LAGEPARAMETER

→ Lageparameter beschreiben die “Lage” der Elemente der Grundgesamtheit bzw. der Stichprobe in Bezug auf die Messskala

→ noch Lokationsmaße genannt

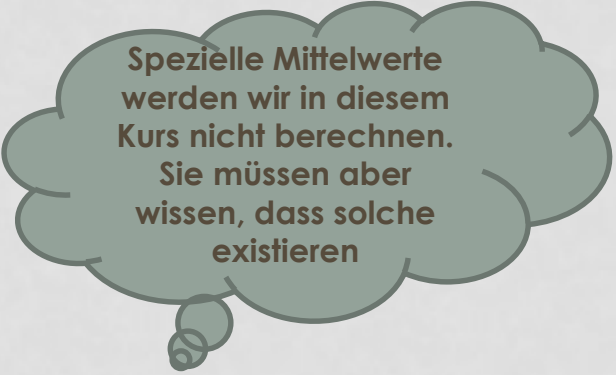
ALLGEMEINE LAGEPARAMETER

Allgemeine Mittelwerte:

- **Modus** \bar{x}_D
- **Median** \bar{x}_Z
- **arithmetisches Mittel** \bar{x}
- **Quantil** \tilde{x}_p

Spezielle Mittelwerte:

- **geometrisches Mittel** \bar{x}_G
- **harmonisches Mittel** \bar{x}_H



Spezielle Mittelwerte
werden wir in diesem
Kurs nicht berechnen.
Sie müssen aber
wissen, dass solche
existieren

MODUS

- **Modus (oder Modalwert)** \bar{x}_D

Der **Modus** oder **Modalwert** ist die am häufigsten auftretende Merkmalsausprägung (**maximale Häufigkeit**). Er wird hauptsächlich für nominale Merkmale verwendet, ist aber auch für alle anderen (diskreten) Merkmalstypen sinnvoll.


Bei klassierten Daten ist der Modalwert die **Mitte der Klasse mit den größten Häufigkeiten**. Diese Klasse nennt man die **Modalklasse**.

Bemerkung:

Gibt es mehrere Merkmalsausprägungen mit der gleichen maximalen Häufigkeit, so existieren mehrere Modalwerte → **Multimodale Verteilungen** (bimodale Verteilung: zwei Modalwerte; trimodale Verteilung: drei Modalwerte; usw.)


MODUS

- **Modus (oder Modalwert) \bar{x}_D :** Merkmalsausprägung, die am häufigsten vorkommt



unimodale Verteilung

Dichtekurve hat nur
ein lokales Maximum



multimodale Verteilung

Dichtekurve hat mehrere lokale
Maxima (bimodale Verteilung,
Trimodale Verteilung usw.)

MEDIAN


- **Median (oder Zentralwert)** \bar{x}_z

Mindestens 50% der Werte liegen links und mindestens 50% rechts des Medians (den Median selbst ggf. mit eingerechnet).

Median ist ein sehr robustes Lokationsmaß. Robuste statistische Kenngrößen sind wenig anfällig gegen Datenausreißer. Man muss die Hälfte der Daten gegen $+\infty$ oder $-\infty$ verschieben, um den Median selbst gegen $\pm\infty$ wandern zu lassen.

MEDIAN

- **Median (oder Zentralwert) \bar{x}_Z** : Wert in der Mitte der geordneten Reihe.
50% der Beobachtungswerte liegen unter dem Median, 50% darüber.



MEDIAN

- **Median (oder Zentralwert)** \bar{x}_z

Für ordinale und metrische Merkmale ist der empirische Median (oder Zentralwert) definiert als:

$$\bar{x}_z := x_{0,5} := \begin{cases} x_{\frac{n+1}{2}}, & \text{falls } n \text{ ungerade} \\ \frac{1}{2} * (x_{\frac{n}{2}} + x_{\frac{n}{2}+1}), & \text{falls } n \text{ gerade} \end{cases}$$

MEDIAN

- Median (oder Zentralwert)

$$\bar{x}_Z$$

Beispiel 1:

Die Anzahl n der Merkmalsausprägungen ist ungerade, z.B. das Alter von 7 Lehrern
($n = 7$)

28	31	40	45	52	53	62
x_1	x_2	x_3	x_4	x_5	x_6	x_7
3 Werte			\bar{x}_Z	3 Werte		

$$\bar{x}_Z = x_{\frac{n+1}{2}} = x_{\frac{7+1}{2}} = x_4 = 45$$

In der Tabelle stehen links und rechts neben dem Median gleich viele Werte.

MEDIAN

- **Median (oder Zentralwert)**

\bar{x}_z

Beispiel 2:

Die Anzahl n der Merkmalsausprägungen ist gerade, z.B. das Alter von 8 Lehrern
($n = 8$)

28	31	40	45	52	53	58	62
x_1	x_2	x_3	x_4	x_5	x_6	x_7	x_8
3 Werte			\bar{x}_z		3 Werte		

$$\bar{x}_z = \frac{1}{2} * (x_{\frac{n}{2}} + x_{\frac{n}{2}+1}) = \frac{1}{2} * (x_{\frac{8}{2}} + x_{\frac{8}{2}+1}) = \frac{1}{2} * (x_4 + x_5) = \frac{1}{2} * (45 + 52) = 48,5$$

Bei einer geraden Anzahl von Werten berechnet man den Median aus den beiden mittleren Werten.

MEDIAN

- **Median (oder Zentralwert)** \bar{x}_z

Bemerkungen:

Falls das betrachtete Merkmal nur ordinal skaliert ist (z.B. Zeugnisnoten), so ist bei geradem n zu beachten, dass der Median nur dann existiert, wenn beide infrage kommenden Merkmalsausprägungen gleich sind.

Beispiel:

bei den Zeugnisnoten 1 2 3 4 5 6 existiert kein Median, denn 3,5 als Zeugnisnote ist nicht üblich.

Aber: 1 2 3 3 4 5 hat den Median 3.

MEDIAN BEI KLASSIERTEN DATEN

- **Median (oder Zentralwert)** \bar{x}_Z

Für metrische Daten in Klassen, kann die exakte Merkmalsausprägung des Medians nicht bestimmt werden → **Näherungswerte für Median**

$$\bar{x}_Z := x_{k-1} + (x_k - x_{k-1}) * \frac{0,5 - F_{k-1}}{f_k}$$

wobei k = **Einfallsklasse** (Klasse mit $F(x)=50\%$)

MEDIAN BEI KLASSIERTEN DATEN

Schritt 1: Bestimmung der Einfallsklasse k

→ Klasse mit $F(x)=50\%$

Schritt 2: Berechnung des Näherungswertes für Median

→ Näherungswert, weil die Verteilung in den Klassen nicht bekannt ist. Es wird angenommen, dass die Beobachtungswerte in den Klassen gleich verteilt sind.

The diagram illustrates the formula for the median of grouped data, \bar{x}_Z , which is highlighted in a yellow box. The formula is:

$$\bar{x}_Z = x_{k-1}^* + (x_k^* - x_{k-1}^*) \cdot \frac{(0,5 - F_{k-1}^*)}{f_k}$$


Labels and arrows point to the components of the formula:

- relative Summenhäufigkeit der Klasse Unterhalb der Einfallsklasse (Anteilswert)**: Points to F_{k-1}^* in the numerator.
- relative Häufigkeit der Einfallsklasse Anteilswert**: Points to f_k in the denominator.
- Untergrenze der Einfallsklasse**: Points to x_{k-1}^* in the first term.
- Obergrenze der Einfallsklasse**: Points to x_k^* in the second term.

A red arrow points to the entire formula box.

MEDIAN BEI KLASSIERTEN DATEN

Beispiel 1:



Das Ergebnis:

Näherungswert für Median aus klassierten Daten $\bar{x}_Z = 434,21$ €.

Der tatsächliche Median der Daten ist 423 €.

Achtung!! Es existiert Fehler der Näherung.

MEDIAN BEI KLASSIERTEN DATEN

Beispiel 2:

Klassen-Nr. i	Größenklassen (cm)	h_i	f_i (%)	H_i	F_i (%)
1	100 b.u. 150	40	40%	40	40%
2	150 b.u. 170	40	40%	80	80%
3	170 b.u. 200	20	20%	100	100%
Summe		100	100%	-	-

Einfallsklasse: $k = 2$


$$\bar{x}_Z = x_{k-1}^* + (x_k^* - x_{k-1}^*) \cdot \frac{(0,5 - F_{k-1})}{f_k}$$

$$\bar{x}_Z = 150 + (170 - 150) \cdot \frac{(0,5 - 0,4)}{0,4} = 150 + 20 \cdot \left(\frac{0,1}{0,4}\right) = 155 \text{ (cm)}$$

MEDIAN BEI KLASSIERTEN DATEN

Beispiel 3:

Umsatz- klassen (€)	Anzahl h_i	Anteil in % f_i	H_i	F_i (%)
10 b.u. 30	60	30%	60	30%
30 b.u. 40	80	40%	140	70%
40 b.u. 70	60	30%	200	100%
Summe	200	100%	-	-



$$\bar{x}_Z = x_{k-1}^* + (x_k^* - x_{k-1}^*) \cdot \frac{(0,5 - F_{k-1})}{f_k}$$

Einfallsklasse $k=2$ (30 b.u. 40)

$$\bar{x}_Z = 30 + (40 - 30) \frac{0,5 - 0,3}{0,4} = 35 \text{ (€)}$$

ARITHMETISCHES MITTEL

- **Arithmetisches Mittel** \bar{x}

Das **arithmetische Mittel** (oder **Mittelwert**, oder **Durchschnitt** genannt) ist sinnvoll für beliebige metrische Merkmale.

$$\bar{x} = \bar{x}_n = \frac{x_1 + x_2 + \cdots + x_n}{n} = \frac{1}{n} \sum_{i=1}^n x_i$$

Statistiker-Witz:

Steht jemand mit einem Fuß auf der Herdplatte und mit dem anderen im Eiskasten, dann sagt der Statistiker: im Durchschnitt ist ihm angenehm warm.

ARITHMETISCHES MITTEL

- **Arithmetisches Mittel**

\bar{x}

Eigenschaften:

- Die Summe der Abweichungen der Einzelwerte vom arithmetischen Mittel ist stets gleich null $\sum(x_i - \bar{x}) = 0$
- bekanntester Mittelwert
- nur für quantitative Merkmale sinnvoll
- empfindlich gegen Ausreißer (Vorsicht bei schiefen Verteilungen!)

ARITHMETISCHES MITTEL AUS HÄUFIGKEITSTABELLEN

- **Arithmetisches Mittel** \bar{x}

$$\bar{x} = \frac{1}{n} \sum_{i=1}^j x_i * h(x_i) = \sum_{i=1}^j x_i * f(x_i)$$

x_1, \dots, x_j

Merkmalsausprägungen

$h(x_1), \dots, h(x_j)$

absolute Häufigkeiten

$f(x_1), \dots, f(x_j)$

relative Häufigkeiten

ARITHMETISCHES MITTEL AUS HÄUFIGKEITSTABELLEN

- **Arithmetisches Mittel** \bar{x}

Fall 1: Absolute Häufigkeit $h(x_i)$

$$\bar{x} = \frac{1}{n} \sum_{i=1}^j x_i * h(x_i) = \frac{1}{n} * (x_1 h(x_1) + x_2 h(x_2) + \dots + x_j h(x_j))$$

$$n = \sum_{i=1}^j h(x_i) = h(x_1) + h(x_2) + \dots + h(x_j)$$

$h(x_i)$ *absolute Häufigkeit der Merkmalsausprägung x_i*

n *Summe der absoluten Häufigkeiten*

j *Anzahl der Merkmalsausprägung x_i*

ARITHMETISCHES MITTEL AUS HÄUFIGKEITSTABELLEN

▪ Arithmetisches Mittel \bar{x}

Beispiel:

Berechnung des arithmetischen Mittels über die absoluten Häufigkeiten:

Note x_i	1	2	3	4	5	6
Anzahl Schüler $h(x_i)$	5	8	14	16	5	2

Schüler insgesamt:

$$n = \sum_{i=1}^6 h(x_i) = 5 + 8 + 14 + 16 + 5 + 2 = 50$$

Durchschnittsnote:

$$\bar{x} = \frac{1}{n} \sum_{i=1}^j x_i * h(x_i) = \frac{1}{50} * (1 * 5 + 2 * 8 + 3 * 14 + 4 * 16 + 5 * 5 + 6 * 2) = \frac{164}{50} = 3,3$$

ARITHMETISCHES MITTEL AUS HÄUFIGKEITSTABELLEN

- **Arithmetisches Mittel** \bar{x}

Fall 2: Relative Häufigkeit $f(x_i) = \frac{h(x_i)}{n}$

$$\bar{x} = \sum_{i=1}^j x_i * f(x_i) = (x_1 f(x_1) + x_2 f(x_2) + \dots + x_j f(x_j))$$

$f(x_i)$ *relative Häufigkeit der Merkmalsausprägung x_i*

n *Summe der absoluten Häufigkeiten*

j *Anzahl der Merkmalsausprägung x_i*

ARITHMETISCHES MITTEL AUS HÄUFIGKEITSTABELLEN

▪ Arithmetisches Mittel \bar{x}

Beispiel:

Berechnung des arithmetischen Mittels über die relativen Häufigkeiten:

Note x_i	1	2	3	4	5	6
Anzahl Schüler $h(x_i)$	5	8	14	16	5	2
Relative Häufigkeit $f(x_i) = h(x_i)/n$	0,1	0,16	0,28	0,32	0,1	0,04

Schüler insgesamt:

$$n = \sum_{i=1}^6 h(x_i) = 5 + 8 + 14 + 16 + 5 + 2 = 50$$

Durchschnittsnote:

$$\bar{x} = \sum_{i=1}^j x_i * f(x_i) = 1 * 0,1 + 2 * 0,16 + 3 * 0,28 + 4 * 0,32 + 5 * 0,1 + 6 * 0,04 = 3,3$$

ARITHMETISCHES MITTEL BEI KLASSIERTEN DATEN

Näherungswert für Arithmetisches Mittel

$$\bar{x} = \frac{1}{n} \sum_{i=1}^k m_i * h_i = \sum_{i=1}^k m_i * f_i$$

m_1, \dots, m_k

Klassenmitten (!!)

h_1, \dots, h_k

absolute Klassenhäufigkeiten

f_1, \dots, f_k

relative Klassenhäufigkeiten

→ Näherungswert, weil die Verteilung in den Klassen nicht bekannt ist. Es wird angenommen, dass die Beobachtungswerte jeweils in den Klassenmitten liegen.

ARITHMETISCHES MITTEL BEI KLASSIERTEN DATEN

- **Arithmetisches Mittel** \bar{x}

Fall 1: Absolute Häufigkeit h_i

$$\bar{x} = \frac{1}{n} \sum_{i=1}^k m_i * h_i = \frac{1}{n} * (m_1 h_1 + m_2 h_2 + \dots + m_k h_k)$$

$$n = \sum_{i=1}^k h_i = h_1 + h_2 + \dots + h_k$$

h_i *absolute Häufigkeit der i-ten Klasse*

n *Summe der absoluten Häufigkeiten*

k *Anzahl der Klassen*

m_i *Klassenmitte der i-ten Klasse*

ARITHMETISCHES MITTEL BEI KLASSIERTEN DATEN

▪ Arithmetisches Mittel \bar{x}

Beispiel:

klassierte Häufigkeitstabelle für das Körpergewicht, Berechnung über die absoluten Häufigkeiten:

Klasse x_i	41 bis 50	51 bis 60	61 bis 70	71 bis 80	81 bis 90
Häufigkeit h_i	20	15	10	4	1
Klassenmitte m_i	45,5	55,5	65,5	75,5	85,5

Der Häufigkeit wird die Klassenmitte zugeordnet. Man unterstellt, dass alle 15 Schüler z. B. der Klasse x_2 das Körpergewicht 55,5 kg haben.

Schüler insgesamt:

$$n = \sum_{i=1}^5 h_i = 20 + 15 + 10 + 4 + 1 = 50$$

Durchschnittsgewicht:

$$\bar{x} = \frac{1}{n} \sum_{i=1}^j h_i * m_i = \frac{1}{50} * (20 * 45,5 + 15 * 55,5 + 10 * 65,5 + 4 * 75,5 + 1 * 85,5) = \frac{2785}{50} = 55,7$$

ARITHMETISCHES MITTEL BEI KLASSIERTEN DATEN

- **Arithmetisches Mittel** \bar{x}

Fall 2: Relative Häufigkeit $f_i = \frac{h_i}{n}$

$$\bar{x} = \sum_{i=1}^k m_i * f_i = m_1 f_1 + m_2 f_2 + \dots + m_k f_k$$

f_i	<i>relative Häufigkeit der i-ten Klasse</i>
n	<i>Summe der absoluten Häufigkeiten</i>
k	<i>Anzahl der Klassen</i>
m_i	<i>Klassenmitte der i-ten Klasse</i>

ARITHMETISCHES MITTEL BEI KLASSIERTEN DATEN

▪ Arithmetisches Mittel \bar{x}

Beispiel:

klassierte Häufigkeitstabelle für das Körpergewicht, Berechnung über die relativen Häufigkeiten:

Klasse x_i	41 bis 50	51 bis 60	61 bis 70	71 bis 80	81 bis 90
Häufigkeit h_i	20	15	10	4	1
Relative Häufigkeit $f_i = h_i/n$	0,40	0,30	0,20	0,08	0,02
Klassenmitte m_i	45,5	55,5	65,5	75,5	85,5

Schüler insgesamt:

$$n = \sum_{i=1}^5 h_i = 20 + 15 + 10 + 4 + 1 = 50$$

Durchschnittsgewicht:

$$\bar{x} = \sum_{i=1}^k m_i * f_i = 45,5 * 0,40 + 55,5 * 0,30 + 65,5 * 0,20 + 75,5 * 0,08 + 85,5 * 0,02 = 55,7$$

MEDIAN VS. MITTELWERT

Beispiel:

Abteilung mit 9 Personen hat folgende Einkünfte in €:

1.200	1.050	950	1.100	900	1.800	6.600	1.150	1.000
-------	-------	-----	-------	-----	-------	-------	-------	-------

$$\bar{x} = 1.660$$

Dieser Durchschnitt liefert ein falsches Bild, weil die Mehrzahl (7 von 9 Personen) höchstens 1.200 € verdient. Der Wert 6.600 € zieht den Mittelwert nach oben.

Man sucht nach einem Wert, der die Verteilung der Einkünfte besser charakterisiert. Dazu werden die Verdienste der Größe nach sortiert:

900	950	1.000	1.050	1.100	1.150	1.200	1.800	6.600
-----	-----	-------	-------	-------	-------	-------	-------	-------

$$\bar{x}_Z = x_{\frac{n+1}{2}} = x_{\frac{9+1}{2}} = x_5 = 1.100$$

Der Median beschreibt die Verteilung besser als der Mittelwert,
Ausreißer haben auf den Median keinen Einfluss.

NEIGUNG / SCHIEFE

Folgende Faustregel setzt Modus, Median und arithmetisches Mittel in Beziehung:

rechtsschiefe (linkssteile) Häufigkeitsverteilung:

Modus < Median < arithmetisches Mittel

$$\bar{x}_D < \bar{x}_Z < \bar{x}$$

linksschiefe (rechtssteile) Häufigkeitsverteilung:

Modus > Median > arithmetisches Mittel

$$\bar{x}_D > \bar{x}_Z > \bar{x}$$


unimodale symmetrische Häufigkeitsverteilung:

Modus \approx Median \approx arithmetisches Mittel

$$\bar{x}_D \approx \bar{x}_Z \approx \bar{x}$$

NEIGUNG / SCHIEFE

Rechtsschiefe Verteilung

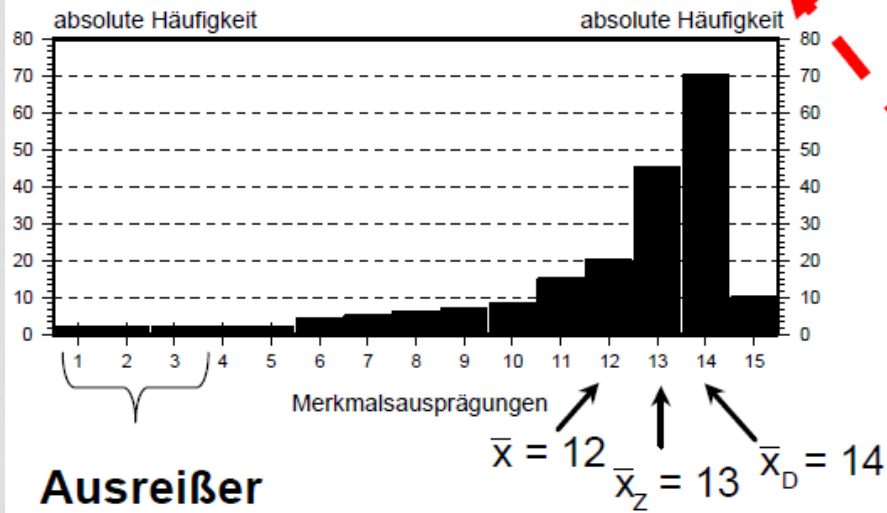


$$\bar{x}_Z < \bar{x}$$



NEIGUNG / SCHIEFE

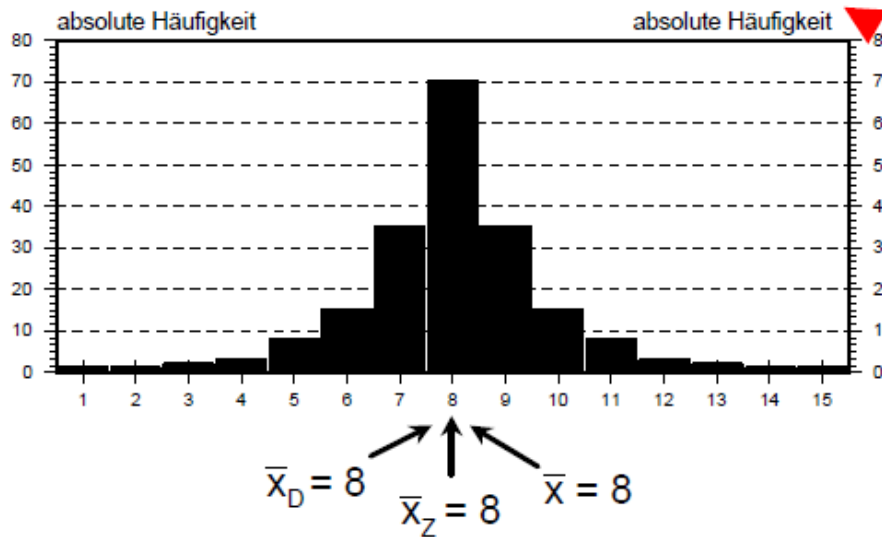
Linksschiefe Verteilung



$$\bar{x}_Z > \bar{x}$$

NEIGUNG / SCHIEFE

Symmetrische Verteilung



$$\bar{x}_Z = \bar{x}$$

BEISPIELÜBUNG

Modus, Median, arithmetisches Mittel, Schiefe

x_i	$h(x_i)$	$f(x_i)$ (%)	$H(x_i)$	$F(x_i)$ (%)
1	1	8,3%	1	8,3%
2	6	50,0%	7	58,3%
3	2	16,7%	9	75,0%
4	2	16,7%	11	91,7%
9	1	8,3%	12	100,0%
Summe	12	100,0%	-	-

$$\bar{x}_D = 2$$

$$\bar{x}_Z = 2$$

$$\bar{x} = \frac{1}{12}(1 \cdot 1 + 2 \cdot 6 + 3 \cdot 2 + 4 \cdot 2 + 9 \cdot 1) = \frac{36}{12} = 3$$

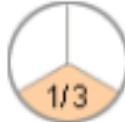


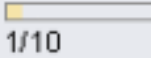
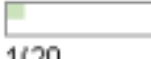
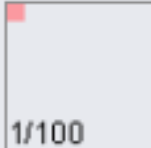
wegen $\bar{x}_Z < \bar{x}$ rechtsschiefe Verteilung

QUANTILE

Ein **Quantil** ist ein Lagemaß in der Statistik.

Quantile teilen eine Verteilung in Abschnitte gleicher Häufigkeit.

Spezielle Quantile:

Benennung der Quantile \tilde{x}_p	Anzahl der Intervalle	
Terzile	3	
Quartile	4	
Quintile	5	
Dezile	10	
Vigintile	20	
Perzentile (Zentile)	100	

QUANTILE

